NOVOCUBE · SOLUTION BRIEF

AIGC 的规模化生产：典型问题与 Novocube 解决方案

AIGC 客户面临的主要问题

视频生成模型已经能够产出可用的镜头。进入批量生产后，问题集中在质量、规模和算力选型三个方面。

质量问题中最常见的是角色漂移，即同一角色在不同镜头中的脸、体型、服装或道具不一致。通常的处理方式是首尾帧校验、单镜审核和反复重新生成，每次重新生成都要占用分钟级的 GPU 时间。重新生成的结果依然具有随机性，审核遗漏的问题往往到后期合成阶段才被发现，此时后续镜头已经基于有偏差的关键帧制作，返工范围广泛扩散。

规模带来的问题在小范围试用时并不明显。用户数和任务量增加后，长任务持续占用 GPU，后续任务只能排队，个别任务出错后反复重试还会拖慢整个队列。模型或工作流升级一次，所有团队的生成结果会同时受到影响。角色设定和未发布的成片属于核心资产，多个团队或多个租户共用一套系统时，数据必须严格隔离。

算力选型的问题在于硬件配置与业务需求脱节。GPU 是 AIGC 业务最主要的成本项，而现有的算力平台和推理服务大多针对大语言模型的负载设计。视频生成显存占用大，任务独占 GPU，单条视频的生成耗时通常在数十秒到数分钟之间，合批收益有限。不同业务对交付时延、并发量和成本的要求差别很大，沿用 LLM 集群的配置或只比较单卡算力，容易出现两类结果：配置不足时，任务无法运行或达不到交付时限；配置过度时，昂贵的 GPU 和互联资源没有转化为有效成片。

Novocube 的核心价值

Novocube 为随机的生成模型提供生产级的控制与治理，使视频生成能够按生产系统的方式稳定运行。这一能力由智能体、AIR 平台和面向业务需求的硬件选型三部分构成。

客户问题	Novocube 的解法	客户获得的能力
质量不可控	Novocube 智能体：执行闭环加质量门禁	生产过程可编排、可记忆、可诊断、可定向修复
规模不稳定	Novocube AIR 平台：统一的治理控制面	算力可调度、租户可隔离、过程可审计、故障半径可控
选型无依据	面向业务需求的硬件选型：平台与算力柜软硬协同	显存、算力、互联、副本数和存储按业务目标配置，以单位有效成片成本比较方案

三部分逐层衔接。智能体控制单次生产过程，AIR 平台让大量生产任务在多租户环境下并行运行且互不干扰，硬件选型让这些任务运行在与业务需求匹配的算力上，在满足交付时延和可用性要求的前提下降低单位成片成本。整体架构如下图所示，自上而下依次为智能体运行时、质量门禁、平台治理、推理服务层和硬件层。前两层由智能体实现，对应执行闭环和质量门禁；平台治理由 AIR 平台实现，故障收敛是其结果；推理服务层承载 H3-Base 的两个分区、文本编码器和音视频 VAE；硬件层由 GPU、网络和存储三类并列的硬件构成，是硬件选型的对象。



需要明确的是，生成模型的随机性无法消除，故障也无法全部提前预见。Novocube 提供的保障是故障可以被观测、回放、隔离和恢复，影响范围保持可控。

典型问题一：角色漂移的成因与控制

角色漂移表面上是某一帧出现错误，实际上是偏差沿工作流逐级累积的结果。其中两个环节源于模型，三个环节源于工程流程。

模型侧的第一个环节是参考约束竞争。一次生成通常需要同时输入多张角色参考图以及背景要求和动作描述，模型不会原样拼接这些素材，它会重新理解并绘制整个画面。参考素材越多，各项约束越容易相互冲突，角色特征在重绘中发生偏差的可能性也越大。第二个环节是随机推理漂移，生成过程本身具有随机性，每次采样的偏向并不固定。这两个环节无法通过工程手段消除，只能在结果产生后识别和拦截。

工程侧的三个环节决定偏差是否被放大。视频生产分为多个阶段，后一阶段以前一阶段的输出作为输入，带有偏差的关键帧一旦进入后续流程，后续的镜头和版本都会继承这一偏差。这类偏差不易察觉，因为画面运动保持连贯，角色身份却已经发生变化。许多生产流程检查角色身份时不够全面严格，也不检查参考资产是否完整，未覆盖的错误被视为合格结果放行。发现问题后，常见的做法是只重新运行出错的叶子节点。如果根源在上游的关键帧，而重新运行时没有重新验证完整的角色身份链，错误会原样保留，并额外消耗一次生成的算力。因此，仅调整模型参数或依靠人工反复重试，都无法根治角色漂移。

Novocube 智能体通过执行闭环控制生产过程。智能体先将制作需求拆解为输入、输出和依赖关系明确的子任务，按子任务类型选择模型和工作流，再以有向无环图的形式执行，并持续记录素材、参数、版本和中间状态。生成完成后，智能体检查结果并定位问题所在的节点，只重试出错的节点及其受影响的下游。由于中间状态和版本均有记录，偏差由哪一个关键帧引入、被哪些镜头继承都可以追溯，重试范围依据诊断结果确定，根源在上游时从上游修复。

执行闭环之上设有四道质量门禁，用于阻止随机性造成的错误进入下一阶段。角色指纹门禁以 SHA-256 锁定参考资产，并比对生成结果与参考资产的角色特征，拦截角色身份偏差以及参考资产被替换或损坏的情况。跨帧一致性门禁检查姿态、运动轨迹和时间连续性。版本完整性门禁锁定工作流 DAG、模型、节点和资产版本，

防止依赖漂移导致结果不可复现。第四道是人工审核，关键镜头、最终成片和发布授权由人工确认，处理自动检查无法判断的创作和合规问题。关键帧须先通过角色指纹和版本完整性检查，才能被后续镜头继承。

典型问题二：规模化后的稳定与隔离

单次生成得到控制之后，第二个问题出现在规模上。用户数增加后，多个租户需要安全、稳定地共享模型、GPU、显存、存储和队列，风险来自资源、边界和版本三个方面。

视频生成的单个任务耗时较长，会持续占用 GPU。不同规格的任务交替运行会产生显存碎片，降低资源利用率，失败任务如果不受限制地重试，还会持续向队列加压。在缺少配额、优先级和背压机制的情况下，一个异常任务就足以拖慢同一队列中的所有用户。不同租户的素材、输出、缓存和密钥必须相互隔离，这些素材多为角色设定、未发布成片等核心资产，一旦发生跨租户泄露，后果比一般的文本服务严重得多。模型、节点和工作流的版本如果缺少统一管理，一次升级或一次依赖漂移就可能同时影响多个队列和多个租户，单个任务的故障会迅速扩大为平台级故障。

Novocube AIR 平台在智能体之下提供统一的治理控制面。入口层负责鉴权、配额、限流和成本预算，每个租户可提交的任务量和可使用的算力在任务进入队列之前即已确定，超额请求在入口层被拦截。调度层根据任务的显存需求、优先级和当前队列压力分配 GPU。队列压力超过阈值时，调度层向入口层反馈以减缓新任务进入，优先级在排队阶段生效，高优先级任务优先获得空闲的 GPU，运行中的任务不会被强制中断。每个任务和每个租户的重试次数设有上限。

租户沙箱同时隔离计算、数据与身份边界。每个任务运行在带租户标识的独立计算命名空间中，只能使用该租户授权的服务账号、密钥和存储空间；素材、模型适配资产、中间结果、缓存及日志均绑定租户身份，所有读取和下载请求都在服务端重新校验租户归属，避免仅依赖对象路径或客户端传入的 URL。缓存默认不跨租户复用，任务结束后，GPU 显存、本地临时文件和运行时凭据会被清理。

持久化输出采用“临时写入、校验、原子发布”的流程。生成中的文件先写入租户专属的暂存区，任务成功并通过完整性与质量检查后，平台校验文件摘要，将对象及其租户、任务、版本、审核状态等元数据一并提交，再原子切换为可交付状态，避免失败任务留下半成品或数据库状态与文件不一致。正式输出存放在租户独立的对象存储命名空间中；高安全等级租户可以使用独立存储桶、存储账户和租户专属加密密钥。租户删除资产或终止服务时，平台同步处理对象版本、缓存、副本和备份保留记录，确保数据在约定期限内完成可验证清除。这样即使执行节点故障、服务重启或客户端断开，已经提交的输出仍可恢复，而其他租户始终无法发现、引用或下载该数据。

可靠性方面，平台以全链路 Trace 记录任务从提交到交付的每个环节，使失败可以定位和回放，并为排队时长、成功率等指标设定 SLO，偏离时告警。某个模型或节点持续失败时自动熔断。新版本经灰度发布验证后再扩大范围，出现问题时回滚到上一个可用版本。故障的影响范围按层级收敛：单个任务的失败不影响同一租户的其他任务，单个租户的异常不影响其他租户，版本引入的问题可以按版本整体撤回。每次生成所用的素材、参数、版本和审核记录完整留存，可供事后追溯。

典型问题三：面向业务需求的硬件选型与成本优化

第三个问题不是简单增加算力，而是根据业务目标选择合适的硬件组合，在满足交付时延和可用性要求的前提下，降低单位成片成本。视频生成没有适用于所有业务的统一配置：模型规模、分辨率和视频时长决定任务能否运行以及最低显存需求；单条视频的交付时限决定 GPU 性能、并行度和卡间互联；并发量与流量峰值决定副本数量、队列容量和资源冗余；素材规模、输出码率与保留周期则决定对象存储和网络带宽。硬件选型必须从这些业务需求反推，不能只比较单卡算力，也不能直接照搬大语言模型集群的配置。

选型不足时，显存无法容纳模型和中间状态，只能频繁卸载，生成时间和失败率随之上升；卡间带宽不足时，多卡并行效率下降，增加 GPU 也不能等比例缩短交付时间。选型过度同样会增加成本：以吞吐为主、可以排队的业务如果统一采用高并行度和高带宽互联，昂贵的互联资源并不会转化为更多有效成片；为偶发峰值长期保留大量空闲 GPU，也会显著抬高单位产出成本。因此，Novocube 将业务目标转换为以下硬件约束。

业务需求	需要评估的指标	对硬件选型的影响
模型、分辨率和视频时长	模型权重、中间状态和峰值显存	决定 GPU 显存容量及单任务最低卡数
单条视频交付时延	单步计算时间、并行效率和通信占比	决定 GPU 计算性能、并行度和卡间互联
并发量与峰值流量	任务到达率、平均执行时间和队列等待时间	决定 GPU 副本数量、资源池规模和弹性策略
输入输出与资产留存	文件大小、读写吞吐和保留周期	决定对象存储容量、缓存和网络带宽
成本与可用性目标	成功率、重试率、资源利用率和冗余要求	决定硬件档位、容灾容量和调度策略

显存首先决定任务能否运行，计算性能决定单条任务需要多久，互联决定增加 GPU 后能否有效加速，GPU 数量决定可以同时承载多少任务。这些指标不能相互替代：显存不足时，更高的理论算力没有意义；单卡或较小并行度已经满足时延要求时，继续增加并行卡数可能只会增加通信和硬件成本；业务瓶颈在并发量时，应优先增加副本，而不是盲目提高单任务并行度。

以 MiniMax H3 这类大规模 DiT 音视频模型为例，其计算方式与 LLM 有明显差异。LLM 逐个 token 解码，推理系统围绕 KV Cache、前缀复用和连续批处理设计；H3 是 33B 参数的单流 DiT，通过多步迭代去噪生成，SGLang 官方配方默认 50 步。在当前开源的全注意力实现下，每一步去噪都要对整段视频和音频的 latent 序列进行全局注意力计算。SGLang 官方基准中，一段 1344×768、约 14.4 秒的带音频视频对应约 10.4 万行序列，不存在可以跨请求复用的前缀。可利用的缓存主要是请求开始前的条件预计算，以及同一请求内相邻去噪步之间的特征复用。其中步间特征复用属于有损加速，是否启用需要结合质量门禁评估。LLM 集群围绕 KV Cache 建设的缓存容量和数据路径因而不能直接转化为视频生成效率。

视频生成的单步去噪是算力受限的稠密矩阵运算，将多个请求合并处理的摊销收益有限，单个任务通常从开始到结束独占一组 GPU，并发主要通过队列和增加副本承接。模型规模、分辨率和时长共同决定显存占用，显存不足时任务无法运行，或只能通过层级卸载以较低效率运行；显存满足之后，去噪计算决定生成时间，单卡计算性能影响单任务速度。数据中心级 GPU 可以让 H3 的单个检查点分区常驻显存，SGLang 官方配方已在 4 张 H100 80GB 上验证，采用张量并行与序列并行混合的拓扑。H3 的开源权重分为 FL2VA 和 Ref2VA 两个分

区，两类任务都需要服务时，应分别部署并按各自的任务量规划容量。参考条件会增加序列长度，参考视频的开销明显高于参考图像，Ref2VA 的容量应按实际参考素材的组合测算。开源的 H3-Base 输出 768p，2K 超分模块目前以托管 API 提供，本节的选型针对可私有化部署的 H3-Base。

只有当模型规模超出单卡显存，或者业务需要进一步压缩单条生成时间时，才需要提高多卡并行度。H3 通常采用 Ulysses 序列并行，显存紧张时与张量并行混用。序列并行在每层注意力前后执行 all-to-all，单次通信量大且处于关键路径，主要受卡间带宽限制。SGLang 官方配方页公开的基准可以说明互联的影响。测试对象是 H3 的 8 步蒸馏变体 VDN-H3，规格为 1344×768、约 14.4 秒的带音频视频。通过 NVLink 互联的 B200 从 1 卡增加到 8 卡，单步去噪时间由 5.93 秒降至 0.85 秒，加速约 7 倍；仅通过 PCIe 互联的 RTX PRO 6000 同样从 1 卡增加到 8 卡，单步时间由 20.27 秒降至 5.43 秒，加速约 3.7 倍，该页说明此时 all-to-all 通信占 GPU 时间的 54%。对于能够接受排队、以总产量为目标的业务，可采用较小的单任务并行度和更多独立副本，以较低的互联成本获得更高并发；对于要求快速出片的业务，则采用 4 卡或 8 卡序列并行并配置高带宽互联。随着 FP8、算子优化和少步蒸馏缩短计算时间，通信占比会进一步提高，高带宽互联对低时延配置的重要性也会增加。

存储和网络需要与计算资源一并选型。视频生成任务持续数分钟，客户端可能断开，执行服务也可能重启，因此任务状态必须持久化，音视频文件通过独立对象存储传输，接口只传递受控 URL。开源推理服务的接口默认从服务器本地路径读取条件素材，并通过下载接口返回成片，多租户生产环境需要在其外层补齐对象存储和访问控制。存储容量由素材、成片、中间结果和保留周期决定，上传下载带宽由并发任务的文件吞吐决定，不能把这部分负载计入 GPU 性能后忽略。Novocube 将任务状态、对象存储和租户沙箱衔接，按租户隔离素材与成片，并将存储容量和带宽作为独立容量项纳入方案和成本核算。

存储按 AIGC 数据的访问特性分为三层。热层是节点本地 NVMe，承载模型权重缓存和任务临时文件；层级卸载时每个去噪步都要顺序读取权重，公开基准显示 PCIe 4.0 NVMe 可以满足，PCIe 3.0 会成为瓶颈，SATA SSD 不可用。温层是全闪共享存储，承载模型仓库、角色参考资产、关键帧、中间结果和租户暂存区，这类数据读取频繁或写入密集，要求高并发读写和按租户隔离。冷层是大容量对象存储，承载成片、历史版本和审计记录，容量按成片码率、产量和保留周期规划。数据随生产流程在三层之间流转：权重从温层的模型仓库分发到各节点的热层；生成中的文件写入温层的租户暂存区，通过校验后原子发布；交付后的成片和审计记录按保留策略转入冷层。

实际选型以客户的真实模型、工作流、分辨率和视频时长进行基准测试，记录峰值显存、P50/P95 生成时间、任务成功率、GPU 利用率以及每 GPU 小时产出的有效成片秒数。满足时延和可用性目标后，再比较候选配置的单位有效成片成本。成本口径不仅包括成功任务的 GPU 时间，还包括失败重试、必要冗余、存储和网络，避免理论峰值更高但实际利用率更低的配置被误判为更优。

最终配置按业务类型分档。吞吐型业务采用小并行度、多副本和队列削峰，不必为高带宽互联支付额外成本；低时延业务采用高性能 GPU、多卡并行和高带宽互联，优先缩短单条视频的生成时间；流量波动明显的业务采用基线容量与弹性资源结合；长期稳定的大批量生产则优先提高常驻资源利用率。同一集群可以划分不同规格的资源池，由调度层按照任务的时延等级、显存需求和成本预算选择资源，避免所有任务统一运行在最高规格硬件上。选型结果最终落实为 Novocube 算力柜的配置：GPU 型号、单节点卡数、卡间互联和存储按档位确定，资源池以算力柜为单位扩展。

硬件选型针对前文架构图中的硬件层：GPU 划分为三种计算池，网络包含卡间互联与业务、存储、管理网络，存储分为热、温、冷三层。

按上述方法，以 H3-Base 为对象的参考选型优先采用消费级显卡，在显存不足以满足业务目标时再升级到 96 GB 专业卡。H3 的权重约 108 GB，其中 DiT 约 62 GB，文本编码器约 46 GB，任何消费级显卡都无法让权重全部常驻显存，必须采用层级卸载，由主机内存和本地 NVMe 承接权重。因此消费级方案的性能首先取决于主机内存容量和 NVMe 的顺序读取速度，其次才是显卡型号。

各档位的推荐配置和能力如下，国产算力作为可选项列入适用的档位。能力数据取自 SGLang 官方配方页的公开测试，分辨率除注明外均为 768p。

档位	推荐配置	达到的能力
批量生产	RTX 4090 D 或 RTX 5090 D v2（24 GB），单卡一副本；国产可选 4 个昇腾 NPU 一副本	RTX 4090 D：5 秒级视频无损约 17 分钟一条，启用量化与跳步后约 5 分钟；昇腾：5 秒视频约 1.7 分钟一条
快速预览	RTX 5090（32 GB），单卡一副本	480p、5 秒视频约 2 分钟一条
分钟级交付	1 至 2 张 RTX PRO 6000（96 GB），运行 8 步蒸馏模型；国产可选 4 个昇腾 NPU 一副本	RTX PRO 6000：15 秒视频 2 至 3 分钟一条；昇腾：5 秒视频约 1.7 分钟一条
一分钟内交付	8 张 RTX PRO 6000（96 GB），运行 8 步蒸馏模型；国产可选 8 个昇腾 NPU 一副本	RTX PRO 6000：15 秒视频的去噪与解码约 47 秒；昇腾：5 秒视频约 55 秒

消费级显卡适合可以排队的批量生产，扩容方式是增加副本，不需要卡间高速互联；单条交付时限在分钟级以内的业务需要升级到 96 GB 专业卡或昇腾 NPU。表中量化与跳步、蒸馏模型以及昇腾配置所用的 Cache-DiT 都属于有损加速，是否用于正式成片由质量门禁的验证结果决定。24 GB 档位的公开基准来自 RTX 4090 D，国内在售的 RTX 5090 D v2 显存同为 24 GB，归入同一档位，性能以实测为准。昇腾的公开基准未注明 NPU 型号，A2 与 A3 两个系列的芯片代际和单卡显存不同，具体型号和卡数以实测确定。各档位的测试条件不同，时间不宜跨档直接比较，最终配置以客户工作流的实测为准。

多卡档位的卡间互联采用以下硬件方案。单卡一副本的档位没有卡间通信，副本之间也不需要高速互联，只需接入业务网络和存储网络。

多卡配置	卡间互联硬件方案	设计要点
2 张 RTX PRO 6000	每卡一条 PCIe 5.0 x16 链路，两卡接在同一个 PCIe 交换芯片或同一颗 CPU 的根端口下	同一副本不跨 CPU。公开基准中，同一交换芯片下的一对卡单步时间为 13.61 秒，跨 CPU 根复合体的一对卡为 15.7 至 17.0 秒
8 张 RTX PRO 6000	8 卡 GPU 服务器，每卡一条 PCIe 5.0 x16 链路，经 PCIe 交换板互联；交换板可选双 PCIe 交换芯片方案，或集成 PCIe 交换的 ConnectX-8 SuperNIC 交换板	该卡没有 NVLink，卡间通信全部经 PCIe，需开启 GPU 间点对点直通。公开基准中 8 卡时 all-to-all 通信占 GPU 时间的 54%，交换板的带宽和拓扑直接决定该档位的时延

多卡配置	卡间互联硬件方案	设计要点
4 或 8 个昇腾 NPU	采用 8 个昇腾处理器的整机，卡间互联使用整机内置的互联，不另行设计	同一副本部署在单台整机内，不跨服务器

三种配置的单个副本都限定在一台服务器内，跨服务器只承载业务和存储流量，因此不需要为卡间通信建设 InfiniBand 或 RoCE 专用网络。

副本数量由产量目标反推：副本数 = 每小时成片秒数需求 ÷（单副本每小时产出上限 × 目标利用率 × 任务成功率）。以每天交付 2 万秒成片、每天有效生产 20 小时为例，每小时需求为 1000 秒。按 70% 的目标利用率和 90% 的任务成功率规划，RTX 4090 D 无损配置需要 100 张，启用量化与跳步后需要 29 张；RTX PRO 6000 单卡运行蒸馏模型需要 6 张；昇腾方案以 4 个 NPU 为一个副本，需要 10 个副本，共 40 个 NPU。利用率和成功率是规划参数，最终取值以客户工作流的基准测试结果为准，不同时长规格和 Ref2VA 任务需要按各自的实测时间另行折算。

容量和成本采用同一口径，以每 GPU 小时产出的有效成片秒数为核心指标，并结合排队时长、任务成功率和重试率评估。平台按输出秒数计量，与入口层的配额和成本预算衔接；按幂等键识别重复请求，避免重复执行；允许任务中途取消，并以重试预算限制失败任务消耗。由此，客户的业务目标、硬件配置、平台调度和扩容决策可以使用同一组指标评估，使硬件投入能够稳定转化为可交付的成片产出。